

目标检测就是寻找目标在图像中的位置(是什么 + 在哪里)。

基本概念

边界框：算法用来框出目标位置的矩形。通常用左上角和右下角坐标 (x_1, y_1, x_2, y_2) ，或中心点坐标加宽高 (x_c, y_c, w, h) 表示。

类别标签：算法判断边界框内物体所属的类别，如：汽车、行人。

置信度：模型对预测结果的把握程度，范围 0 到 1。

交并比(Intersection over Union, IoU)：衡量预测框与真实标注框重合程度的数学指标。IoU 越接近 1，定位越准。公式如下：

$$\text{IoU} = \frac{\text{两个框的交集面积}}{\text{两个框的并集面积}}$$

传统特征工程方法(2012年以前)

传统方法的基本步骤：

1. 使用不同尺寸的滑动窗口从左到右、从上到下扫遍整张图片，产生成千上万个候选框。
2. 专家利用物理学和几何学手工设计能够代表物体特征的数学算子，把上一步截取出来的图像区域，转换成计算机能理解的特征向量。
3. 将提取出的特征向量丢给传统的机器学习分类器(如 SVM、AdaBoost)，让它判断这个窗口里到底是不是我们要找的物体。

三个经典的传统方法：

- Viola-Jones 人脸检测器(2001年)：利用 Haar 特征、积分图与 AdaBoost 级联分类器，在极低的算力下首次实现了人脸的实时检测。
- HOG + SVM(2005年)：提出方向梯度直方图(Histogram of Oriented Gradients, HOG)，通过提取局部的形状与边缘特征进行识别，曾确立为行人检测领域的行业标准。
- DPM(Deformable Part Model, 2008年)：基于可变形部件模型，将目标解构为多个部件的组合，并允许部件间存在一定的弹性空间位移，该机制极大提升了模型对姿态变化和部分遮挡的鲁棒性。

传统方法的局限性：

- 多尺度的滑动窗口机制导致计算量过高。
- 人工设计的特征泛化能力有限，难以适应复杂光照、严重遮挡等非理想条件。

深度学习方法(2012年至今)

两阶段检测器

将检测任务解耦为两步：

1. 首先生成候选区域
2. 随后对这些区域进行特征提取、类别判别并且画出边界框。

代表算法有：

- Fast R-CNN
- Faster R-CNN

技术特性:

- 定位与分类精度较高，对小目标具备较强的检测能力。
- 整体计算开销较大，推理延迟偏高。

单阶段检测器

摒弃候选区域生成步骤，直接将图像划分网格，每个网格里直接检测是什么，在哪里。

代表算法:

- YOLO(You Only Look Once)
- SSD(Single Shot MultiBox Detector)。

技术特性:

- 推理速度极快。
- 小目标定位精度上略逊色。

基于 Transformer 的检测器

无论是两阶段还是单阶段检测器，都需要做非极大抑制，因为会在图像上密集地检测，导致同一个物体上会叠着好几个边界框。

引入自注意力机制，模型能够全局感知，直接输出精准且无重复的检测结果，免除了非极大值抑制等去重后处理步骤。

代表算法: DETR(DEtection TRansformer) 及其衍生模型。

技术特性:

- 全局感知。
- 模型训练的收敛周期较长。