

运动恢复结构(Structure From Motion, SFM)的落地场景举例：

- 三维重建：比如把互联网上不同人拍的同一景点的海量二维照片，拼成一个完整的三维模型。
- 机器人定位与控制：通过计算相机的位姿，反推机器人在物理空间中的绝对位置，从而进行导航。

SFM 与 SLAM(同步定位与建图)的区别：

- SLAM：处理的是连续的视频序列，主要诉求是快(实时性)，因此通常会牺牲或者简化某些优化步骤，精度相对较低。
- SFM：处理的往往是无序、离散的照片(比如网上随便爬取的图)，它的计算过程较慢，但它的精度非常高。

世界坐标系 $X = (X_w, Y_w, Z_w)$ 到像素平面坐标系 $x = (u, v)$ 的过程为(齐次坐标)：

$$\begin{bmatrix} z \cdot u \\ z \cdot v \\ z \end{bmatrix} = \underbrace{\begin{bmatrix} k_{x'} \cdot f & -k_{x'} \cdot f \cdot \cot \theta & u_0 & 0 \\ 0 & \frac{k_{y'} \cdot f}{\sin \theta} & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}}_{\text{相机内参矩阵}} \cdot \underbrace{\begin{bmatrix} R_{11} & R_{12} & R_{13} & t_1 \\ R_{21} & R_{22} & R_{23} & t_2 \\ R_{31} & R_{32} & R_{33} & t_3 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{\text{相机外参矩阵}} \cdot \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

投影矩阵 M 为内参矩阵和外参矩阵的乘积：


$$M = [K \quad 0] \cdot \begin{bmatrix} R & T \\ 0^\top & 1 \end{bmatrix} = [KR \quad KT] = K \cdot [R \quad T]$$

SFM 问题的数学描述

某个 3D 点 X_j 在第 i 张图像中的对应点的像素坐标 x_{ij} ， M_i 为第 i 个相机的投影矩阵， $i = 1 \cdots m, j = 1 \cdots n$ 。

$x_{ij} = M_i X_j$ ，需要求解：

- m 个摄像机的投影矩阵 $M_1 \cdots M_m$ (Motion)。
- n 个 3D 点 $X_1 \cdots X_n$ 的坐标 (Structure)。



摄像机的外参数是一直在变化的，也就相当于摄像机的位置是一直在运动的，而又把 n 个三维点的坐标看作是结构，所以称为运动恢复结构问题。

三种典型的运动恢复结构任务

欧式结构恢复


这是最贴近真实物理世界的一种恢复方式，但前提是已经标定了相机的内参矩阵 K 。

某个 3D 点 X_j 在第 i 张图像中的对应点的像素坐标 x_{ij} ， M_i 为第 i 个相机的投影矩阵， $i = 1 \cdots m, j = 1 \cdots n$ 。

$x_{ij} = M_i X_j = K_i \cdot [R_i \quad T_i] X_j$ ，需要求解：

- m 个摄像机的外参 $R_1 \cdots R_m$ 和 $T_1 \cdots T_m$ 。
- n 个 3D 点 $X_1 \cdots X_n$ 的坐标。

两视图的欧式结构恢复问题：



只要求解第二个摄像机的外参 R 和 T 。

两视图的欧式结构恢复问题计算步骤

1. 先用 SIFT 特征找出两张图像上的关键特征点，并进行配对。
2. 匹配经常会有错，所以要用 RANSAC(随机采样一致性)算法来剔除那些离谱的误匹配点。
3. 基于选出的好点，通过归一化的八点法计算出基础矩阵 F ，再由 $F = (K_2^{-1})^T E K_1^{-1}$ 计算出本质矩阵 $E = K_2^T F K_1$ 。

计算基础矩阵 F 时用到的方程是：

$$x_2^T F x_1 = 0$$

F 无法确定符号以及尺度，因为 $-F$ 和 kF 都满足这个方程，从而 E 也无法确定符号和尺度。

4. 对本质矩阵 E 进行奇异值分解, 结果是:

$$E = T_{\times} R = U \begin{bmatrix} \sigma_1 & & \\ & \sigma_2 & \\ & & 0 \end{bmatrix} V^{\top}$$

为了从 U 和 V 中提取出 R 和 T , 需要引入一个绕 Z 轴旋转 90 度的特殊正交矩阵 W :

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

平移向量 T 对应于矩阵 U 的最后一列(记为 u_3)。但图像只能告诉我们相机沿着哪条线移动了, 无法告诉我们是正向还是反向移动的。所以:

$$T = u_3 \quad \text{or} \quad -u_3$$

在从 U 和 $V^{\top}$ 重构旋转矩阵 R 时, 我们可以使用正 90 度旋转 W , 也可以使用负 90 度旋转 $W^{\top}$ 。因此产生两个合法的旋转矩阵:

$$R = UWV^{\top} \quad \text{or} \quad UW^{\top}V^{\top}$$


所以就有四种可能的 R 与 T 组合, 从而第二个相机的投影矩阵 M_2 有四种可能。

5. 遍历第二个相机的投影矩阵 M_2 的四种可能, 选取一个点或多个点通过:

$$X_j^* = \arg \min_{X_j} (d^2(x_{1j}, M_1 X_j) + d^2(x_{2j}, M_2 X_j))$$

重建出 $3D$ 点 X_j 的坐标, 由于 $3D$ 点必须在两个相机的正前方, 所以深度为正:

- 如果只选一个点: 正确的 R 与 T 组合能够保证 $3D$ 点在两个相机坐标系下的深度(z 轴坐标)均为正。
- 如果选择多个点: 选择在两个摄像机坐标系下深度均为正的个数最多的那组 R 与 T 。



仿射结构恢复

物体离相机非常远，或者物体的深度变化相对较小时，透视效应就会减弱，这时可以把相机模型变为弱透视投影相机，投影矩阵为：

$$M = \begin{bmatrix} A_{2 \times 3} & b_{2 \times 1} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}$$

某个 3D 点 X_j 在第 i 张图像中的对应点的像素坐标 x_{ij} ， M_i 为第 i 个相机的投影矩阵， $i = 1 \cdots m, j = 1 \cdots n$ 。

x_{ij}^E 和 X_j^E 分别表示 3D 点在像素平面中的欧式坐标和在世界坐标系中的欧式坐标：

$$x_{ij} = \begin{bmatrix} x_{ij}^E \\ 1 \end{bmatrix} = M_i X_j = \begin{bmatrix} A_i & b_i \\ \mathbf{0} & 1 \end{bmatrix} \begin{bmatrix} X_j^E \\ 1 \end{bmatrix}$$

所以 $x_{ij}^E = A_i X_j^E + b_i$ ，需要求解：

- m 个摄像机的投影矩阵 $M_1 \cdots M_m$ (即 $A_1 \cdots A_m$ 和 $b_1 \cdots b_m$)。
- n 个 3D 点 $X_1 \cdots X_n$ 的坐标。

因式分解法

1. 数据中心化：把同一张图像上的所有点的欧式坐标减去它们的均值，将原点移到质心：

$$\begin{aligned} \hat{x}_{ij}^E &= x_{ij}^E - \frac{1}{n} \sum_{k=1}^n x_{ik}^E \\ &= A_i X_j^E + b_i - \frac{1}{n} \sum_{k=1}^n A_i X_k^E - \frac{1}{n} \sum_{k=1}^n b_i \\ &= A_i \left(X_j^E - \frac{1}{n} \sum_{k=1}^n X_k^E \right) \\ &= A_i \hat{X}_j^E \end{aligned}$$

2. 构建测量矩阵并分解：把去均值后所有点的坐标 $\hat{x}_{ij}^E$ 排成一个大矩阵 D ：

$$D = \begin{bmatrix} \hat{x}_{11}^E & \hat{x}_{12}^E & \cdots & \hat{x}_{1n}^E \\ \hat{x}_{21}^E & \hat{x}_{22}^E & \cdots & \hat{x}_{2n}^E \\ \vdots & \vdots & & \vdots \\ \hat{x}_{m1}^E & \hat{x}_{m2}^E & \cdots & \hat{x}_{mn}^E \end{bmatrix}_{2m \times n} = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_m \end{bmatrix}_{2m \times 3} \begin{bmatrix} \hat{X}_1^E & \hat{X}_2^E & \cdots & \hat{X}_n^E \end{bmatrix}_{3 \times n} = MS$$

$$\text{rank}(D) \leq 3$$

M 矩阵代表运动， S 矩阵代表结构。

3. 对测量矩阵 D 做紧凑版奇异值分解：

$$\begin{aligned} D &= U \Sigma V^\top \\ U &: 2m \times n \\ \Sigma &: n \times n \\ V^\top &: n \times n \end{aligned}$$

$\text{rank}(D) \leq 3$ ，最多有三个非零奇异值，所以：

$$D = (\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3) \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \sigma_2 & 0 \\ 0 & 0 & \sigma_3 \end{bmatrix} \begin{pmatrix} \mathbf{v}_1^\top \\ \mathbf{v}_2^\top \\ \mathbf{v}_3^\top \end{pmatrix} = U_3 \Sigma_3 V_3^\top$$

$$M = U_3, S = \Sigma_3 V_3^\top.$$

问题：恢复出来的三维结构可能处于一种扭曲状态，因为对任何一个 3×3 的可逆阵 H ：

$$\begin{aligned} M^* &= MH, S^* = H^{-1}S \\ D &= M^* S^* \end{aligned}$$

导致恢复出来的结果是有歧义的，需要引入额外约束条件，才能拉回到正常的欧式空间。

透视结构恢复

最复杂、也是最通用的一种情况，它不假设物体很远，也不假设已知相机内参，手上只有一堆普通的、带有“近大远小”透视效应的二维照片

透视结构恢复歧义： $\mathbf{x}_{ij} = M_i \mathbf{X}_j$ ，对任何可逆阵 $H_{4 \times 4}$ ， $M'_i = M_i H^{-1}$ ， $\mathbf{X}'_j = H \mathbf{X}_j$ ，都有 $\mathbf{x}_{ij} = M'_i \mathbf{X}'_j$ 。

两视图情况下的代数方法

1. 通过归一化的八点法求解出两个视图间的基础矩阵 F 。

由于透视歧义，总存在一个可逆的 H 使得：

$$\begin{aligned} M'_1 &= M_1 H^{-1} = [I_{3 \times 3} \quad \mathbf{0}_{3 \times 1}] \\ M'_2 &= M_2 H^{-1} = [A_{3 \times 3} \quad \mathbf{b}_{3 \times 1}] \\ \mathbf{x}_{1j} &= M_1 \mathbf{X}_j = M'_1 H \mathbf{X}_j = [I \quad \mathbf{0}] \mathbf{X}'_j \\ \mathbf{x}_{2j} &= M_2 \mathbf{X}_j = M'_2 H \mathbf{X}_j = [A \quad \mathbf{b}] \mathbf{X}'_j \\ \mathbf{x}_{2j} &= [A \quad \mathbf{b}] \mathbf{X}'_j = (A[I \quad \mathbf{0}] + [O \quad \mathbf{b}]) \begin{bmatrix} \mathbf{X}'_j \\ 1 \end{bmatrix} \\ &= A[I \quad \mathbf{0}] \begin{bmatrix} \mathbf{X}'_j \\ 1 \end{bmatrix} + [O \quad \mathbf{b}] \begin{bmatrix} \mathbf{X}'_j \\ 1 \end{bmatrix} \\ &= A[I \quad \mathbf{0}] \mathbf{X}'_j + \mathbf{b} \\ &= A \mathbf{x}_{1j} + \mathbf{b} \end{aligned}$$

$$\begin{aligned} \mathbf{x}_{2j} \times \mathbf{b} &= (A \mathbf{x}_{1j} + \mathbf{b}) \times \mathbf{b} = A \mathbf{x}_{1j} \times \mathbf{b} \\ \mathbf{x}_{2j}^\top (\mathbf{x}_{2j} \times \mathbf{b}) &= \mathbf{x}_{2j}^\top (A \mathbf{x}_{1j} \times \mathbf{b}) = 0 \\ \mathbf{x}_{2j}^\top (\mathbf{b} \times A \mathbf{x}_{1j}) &= \mathbf{x}_{2j}^\top (\mathbf{b} \times A) \mathbf{x}_{1j} = 0 \end{aligned}$$

在极几何中，两张图像中的对应点满足 $\mathbf{x}_2^\top F \mathbf{x}_1 = 0$ ，所以 $F = \mathbf{b}_\times A$ 。

$F^\top \mathbf{b} = (\mathbf{b}_\times A)^\top \mathbf{b} = A^\top \mathbf{b}_\times^\top \mathbf{b} = -A^\top \mathbf{b}_\times \mathbf{b} = -A^\top (\mathbf{b} \times \mathbf{b}) = 0$ ， F 为 3×3 矩阵且 $\text{rank}(F) = 2$ ，所以 $F^\top$ 奇异值分解为：

$$F^{\top} = (\mathbf{u}_1 \quad \mathbf{u}_2 \quad \mathbf{u}_3) \begin{bmatrix} \sigma_1 & & \\ & \sigma_2 & \\ & & 0 \end{bmatrix} \begin{pmatrix} \mathbf{v}_1^{\top} \\ \mathbf{v}_2^{\top} \\ \mathbf{v}_3^{\top} \end{pmatrix}$$

所以 $F^{\top} \mathbf{v}_3 = 0$, 方程 $F^{\top} \mathbf{b} = 0$ 在尺度上不确定, 为了得到一个唯一确定解, 必须给它施加一个约束条件。最常用、也最方便的约束就是 $\|\mathbf{b}\| = 1$, 所以 $\mathbf{b} = \mathbf{v}_3$ 。

$$\mathbf{b}_{\times}(-\mathbf{b}_{\times} F) = -(\mathbf{b}\mathbf{b}^{\top} - \|\mathbf{b}\|^2 I)F = -(O - \|\mathbf{b}\|^2 I)F = \|\mathbf{b}\|^2 F = F = \mathbf{b}_{\times} A$$

所以 $A = -\mathbf{b}_{\times} F$ 。

2. 利用基础矩阵 F 估计出两个摄像机的投影矩阵:

$$\begin{aligned} M_1' &= [I_{3 \times 3} \quad \mathbf{0}_{3 \times 1}] \\ M_2' &= [-\mathbf{b}_{\times} F \quad \mathbf{b}_{3 \times 1}] \end{aligned}$$

3. 利用

$$\mathbf{X}_j'^* = \arg \min_{\mathbf{X}_j'} (d^2(\mathbf{x}_{1j}, M_1' \mathbf{X}_j') + d^2(\mathbf{x}_{2j}, M_2' \mathbf{X}_j'))$$

计算出 3D 点的坐标

m 个视图下的代数方法(增量法)

1. 在 m 张图片中, 挑选两张重叠度高、特征点匹配质量好的图片(如视图 1 和视图 2), 然后利用两视图情况下的代数方法求解出两个视图的投影矩阵 M_1 和 M_2 并利用匹配的 2D 像素点, 计算出第一批 3D 点坐标。
2. 在视图 3 上寻找与已有 3D 点对应的 2D 像素点, 此时已经算出的 3D 点坐标变为已知条件(相当于虚拟的标定板), 而视图 3 的相机矩阵 M_3 为未知条件, 通过摄像机标定的方法求出 M_3 。
3. 由于相机 3 走到了新的位置, 视图 3 肯定有视图 1 没拍到的新区域, 但这些新区域能和视图 2 产生重叠, 所以利用它们之间全新的 2D 匹配点, 计算算出新一批的 3D 点, 并将这些新计算出的 3D 点加入到全局 3D 坐标库中
4. 重复第二步和第三步。当视图 4 加入时, 它可以利用全局 3D 坐标库来标定自己, 然后再计算出更新的 3D 点加入到全局 3D 坐标库, 给视图 5 用。

捆绑调整

捆绑调整通常作为最后一步, 代数法求解出来的结果通常用作捆绑调整的初始解。

$$\text{error}(M, X) = \sum_{i=1}^m \sum_{j=1}^n d^2(\mathbf{x}_{ij}, M_i X_j)$$

$\mathbf{x}_{ij}$ 为第 i 张照片上, 实际提取出来的第 j 个特征点的像素坐标。

M_i 是代数法估算出的相机矩阵, X_j 是代数法估算出的三维点坐标。

捆绑调整的目标是: 不断微调所有的相机参数 M 和三维点坐标 X , 使得这个总误差 error 降到最低。

一般用牛顿法或 L-M 方法(Levenberg-Marquardt)来优化。